

# M18 Virtuální paměť a paměť cache

- virtuální paměť
  - technika dovolující programům využívat více paměti než je jí fyzické
  - koncept vytváří iluzi velkého, spojitého adresového prostoru pro každou běžící aplikaci
  - paging
    - virt. pam. prostor je rozdělen na malé bloky nazývané stránky (pages)
    - RAM je rozdělena do bloků stejné velikosti jako v prostoru - rámce
    - když program potřebuje přístup k určité stránce, OS zjistí, zda je tato stránka již načtena do rámce; pokud není, dojde k výpadku stránky (page fault) a OS načte potřebnou stránku z diskového úložiště do volného rámce ve fyzické paměti
  - segmentace
    - virtuální paměť může být také rozdělena do segmentů různé velikosti odpovídající logickým částem programu (kód, data a zásobník)
    - segmenty mohou být umístěny kdekoli v adresním prostoru
    - segmenty mohou růst nebo se zmenšovat podle potřeby
  - page tables
    - OS používá tabulky stránek k mapování virtuálních adres na fyzické adresy
    - tabulka stránek obsahuje záznamy určující kde je každá stránka virtuální paměti uložena ve fyzické paměti
    - když procesor potřebuje přístup k určité virtuální adrese, nejprve zkontroluje tabulku stránek, aby zjistil odpovídající fyzickou adresu
  - swapování - pokud není dostatek fyzické paměti pro všechny aktuálně běžící procesy, operační systém může přenést některé stránky z fyzické paměti na disk do swapovacího prostoru
  - každý proces má svůj vlastní virtuální adresní prostor - vyšší bezpečnost a stabilita systému
  - ochrana paměti mezi procesy - jeden proces nemůže narušit paměť jiného procesu
- cache
  - rychlá paměť, která slouží k dočasnému ukládání často používaných dat nebo instrukcí
  - umístěna mezi procesorem a hlavní pamětí (RAM)
  - cílem je zrychlit výkon systému tím, že sníží dobu potřebnou k přístupu k datům
  - multilevel cache
    - v moderních procesorech
    - každá úroveň má různé charakteristiky (rychlost, velikost)
    - určena k optimalizaci přístupu k datům na různé úrovni hierarchie paměti

## Logické souvislosti s cache

- logické souvislosti určují, jaká data by měla být uložena v cache a jak by měla být spravována
- princip prostorové lokalizace (Spatial Locality)
  - pokud byl přístup k určité adrese v paměti, je vysoká pravděpodobnost, že blízké adresy budou také přístupné brzy
  - cache často ukládá bloky paměti (například několik po sobě jdoucích adres) namísto jednotlivých adres
- princip časové lokalizace (Temporal Locality)
  - pokud byla nedávno přístupná určitá paměťová adresa, je vysoká pravděpodobnost, že k ní bude znovu přístup v blízké budoucnosti
  - cache uchovává nedávno přístupná data, aby mohla být rychleji dostupná při opakovaných přístupech
- hierarchie paměti
  - různé úrovně paměti mají různé rychlosti a velikosti
  - nejrychlejší a nejmenší paměť je umístěna nejbližší procesoru (L1 cache); pomalejší a větší paměť je dále (RAM, pevný disk)
- algoritmy pro správu cache
  - určují, která data budou uložena a která budou odstraněna, když je cache plná
  - algoritmy využívají logické strategie pro maximalizaci cache hit rate
  - LRU (Least Recently Used) - nahrazuje nejméně nedávno použitá data

- FIFO (First In, First Out) - nahrazuje data v pořadí, v jakém byla do cache uložena
- LFU (Least Frequently Used) - nahrazuje data, která byla nejméně často přístupována; kombinace časové a prostorové lokalizace
- přednačítání (Prefetching) - cache může předem načíst data, která ještě nebyla požadována, ale jsou pravděpodobně potřebná v blízké budoucnosti

## Konzistence dat v cache

- nesmí dojít k situacím, kdy jsou stará nebo neplatná data používána místo aktuálních dat
- write strategy
  - strategie zápisu určují, jakým způsobem jsou data zapisována
  - write-through
    - data jsou zapisována do cache a zároveň okamžitě do RAM
    - vysoký úroveň konzistence; pomalejší
  - write-back
    - data jsou zapisována pouze do cache a do RAM jsou zapsána až tehdy, když jsou z cache odstraněna
    - rychlejší; složitější správa paměti
- coherence protocols (Protokoly pro zajištění konzistence)
  - v systémech s více cache
  - MESI Protocol (Modified, Exclusive, Shared, Invalid)
    - každá cache line (řádek) může být ve čtyřech stavech: Modified (M), Exclusive (E), Shared (S), Invalid (I)
    - pokud je jedna cache line v modifikovaném stavu, žádná jiná cache nemá kopii této cache line ve stavu exclusive nebo shared
  - MOESI Protocol (Modified, Owner, Exclusive, Shared, Invalid) - rozšiřuje MESI protokol o stav Owner (O)
  - dragon protocol\
    - v multiprocessorových systémech
    - v situacích, kdy více procesorů sdílí stejné paměťové adresy
- synchronizace a invalidace
  - invalidate on write - při zápisu do cache jsou ostatní kopie dané cache line invalidovány; žádná jiná cache nemůže používat zastaralá data
  - update on write - při zápisu do cache jsou aktualizovány i ostatní kopie dané cache line; všechny cache mají aktuální data
- atomic operations
  - zejména v systémech s více procesory nebo jádry
  - zajišťují, že při čtení a zápisu dat nedochází k nekonzistentním stavům
- konzistenční protokoly v multiprocessorových systémech
  - snooping-based protocols - každá cache monitoruje (snoops) sběrnici pro zjištění operací, které mohou ovlivnit její vlastní kopie dat
  - directory-based protocols - používá centrální nebo distribuovaný adresář, který sleduje, která cache má kopii které paměťové adresy a spravuje aktualizace a invalidace dat

## Vyřazování a aktualizace cache

- h

## Adresa na sběrnici

- h

## Vznik fyzické adresy

-